

Algorithmes Évolutionnaires

Introduction

Les algorithmes évolutionnaires (AE) sont une famille de métaheuristiques stochastiques inspirées du processus d'évolution naturelle darwinienne. Introduits dans les années 1970, ils sont parmi les premières méthodes de ce type.

Le principe central est la **sélection naturelle** ou “survivance du plus apte” : les individus les mieux adaptés ont une plus grande probabilité de se reproduire et de transmettre leurs caractéristiques à la génération suivante.

Cette approche permet de faire émerger des solutions de haute qualité pour un problème donné en faisant **évoluer une population de solutions candidates** à travers des opérateurs de variation (mutation, croisement) et de sélection.

Familles d'Algorithmes Évolutionnaires

- **Algorithmes Génétiques (GA)** – John Holland
 - **Stratégies d'Évolution (ES)** – Ingo Rechenberg
 - **Programmation Génétique (GP)** – Lawrence J. Fogel, John R. Koza
-

Principes Fondamentaux des Algorithmes Génétiques

Caractéristiques Clés

- **Basés sur une population** : explorent simultanément plusieurs régions de l'espace de recherche.
- **Opérateurs probabilistes** : utilisent le hasard mais sont guidés par la fitness (adaptation).
- **Capacité de recherche globale** : moins sujets aux minima locaux que les méthodes purement déterministes.
- **Optimisation “boîte noire”** : ne nécessitent pas d'informations sur les dérivées ou le gradient.

Représentation et Encodage

Chaque individu de la population correspond à une solution (un point dans l'espace de recherche S). Le choix de la représentation est crucial.

Types d'encodage courants : - **Encodage binaire** : pour des problèmes comme MaxOne. - **Encodage à valeur réelle** : pour l'optimisation continue. - **Encodage par permutation** : pour les problèmes d'ordonnancement (ex : TSP).

Le niveau d'adaptation d'un individu est mesuré par sa **fitness**.

Processus Évolutionnaire d'un Algorithme Génétique



Étapes Détaillées

1. Initialisation

- Génération aléatoire d'une population de n individus (typiquement quelques dizaines à quelques centaines).
- Pas de connaissance a priori nécessaire.

2. Évaluation

- Calcul de la fonction de fitness pour chaque individu.
- Dans ce cours, on se concentre sur la **maximisation** de la fitness.

3. Sélection

- Choix des individus qui deviendront parents de la génération suivante.
- Principe de **proportionnalité à la fitness** : les individus les plus aptes ont une probabilité plus élevée d'être sélectionnés.

- Préservation d'une certaine stochasticité : les individus moins aptes peuvent parfois se reproduire, ce qui maintient la diversité.

4. Croisement (Crossover)

- Mélange d'information entre deux parents pour créer une descendance combinant leurs traits avantageux.
- Appliqué avec une probabilité $p_{\text{crossover}}$.
- Si non appliqué, la descendance est une copie exacte des parents.

5. Mutation

- Source principale de nouveauté génétique, essentielle pour maintenir l'exploration.
- Appliquée avec une probabilité p_{mutation} sur chaque gène de chaque individu.
- Simule des erreurs de transcription et du bruit exogène.

6. Élitisme

- Pour ne pas perdre la meilleure solution trouvée jusqu'à présent, elle est automatiquement insérée dans la nouvelle génération.
- Implémenté en remplaçant l'individu le moins apte par le meilleur.

Paramètres Guidés (Guiding Parameters)

- **Taille de la population (n)** : contrôle l'exploration simultanée.
- **Probabilité de croisement ($p_{\text{crossover}}$)** : contrôle la recombinaison des solutions.
- **Probabilité de mutation (p_{mutation})** : contrôle l'introduction de nouveauté.
- **Taux d'élitisme** : nombre d'individus directement conservés.
- **Pression de sélection** : force avec laquelle la sélection favorise les meilleurs individus.

Exploration vs Exploitation

L'efficacité des AE repose sur l'équilibre entre deux forces :

- **Exploitation (Intensification)** : raffiner les bonnes solutions déjà trouvées.
 - *Opérateur principal* : Sélection
- **Exploration (Diversification)** : rechercher dans de nouvelles régions de l'espace.
 - *Opérateur principal* : Mutation
 - *Contribution secondaire* : Croisement

Les paramètres p_{mutation} et $p_{\text{crossover}}$ permettent d'ajuster cet équilibre.

Opérateurs de Sélection Alternatives

1. Sélection Proportionnelle à la Fitness (Roulette Wheel)

- Probabilité $p_i = \frac{f_i}{\sum_j f_j}$
- Limitation : perte de sélectivité lorsque les fitness se rapprochent.

2. Sélection par Rang (Rank Selection)

- Basée sur le rang des individus (après tri par fitness), pas sur leur valeur absolue.
- Évite les problèmes de sensibilité aux valeurs extrêmes.

Sélection Linéaire par Rang :

$$p_i = \frac{1}{n} \left[\beta - 2(\beta - 1) \frac{i - 1}{n - 1} \right], \quad i = 1, \dots, n$$

où $\beta \in [1, 2]$ contrôle la pression de sélection.

3. Sélection par Tournoi (Tournament Selection)

- Tirage aléatoire de k individus, sélection du meilleur.
 - Contrôle précis de la pression via k (taille du tournoi).
 - Avantages : simple, robuste, ne nécessite pas de fitness normalisées.
-

Temps de Prise de Contrôle (Takeover Time)

Concept théorique mesurant l'intensité de la sélection :

- **Temps de prise de contrôle (τ)** : nombre de générations nécessaires (sans croisement ni mutation) pour que le meilleur individu domine toute la population.
- τ petit $\rightarrow$ sélection forte (convergence rapide, risque de convergence prématurée).
- τ grand $\rightarrow$ sélection faible (meilleure diversité, convergence lente).

Modélisation par équation logistique :

$$\frac{dm}{dt} = \alpha m \left(1 - \frac{m}{n} \right)$$

où $m(t)$ est le nombre de copies du meilleur individu.

Opérateurs de Croisement et Mutation Avancés

Croisement

- **À un point (single-point)** : coupe en un point aléatoire.
- **À deux points (two-point)** : échange d'un segment entre deux points.
- **Uniforme (uniform)** : chaque gène choisi aléatoirement d'un parent ou de l'autre.

Mutation

Pour des espaces de recherche complexes (ex : permutations pour le TSP), des opérateurs spécifiques sont nécessaires :

- Déplacement d'une ville
 - Échange de deux villes
 - Échange de deux segments
-

Populations Structurées

Alternative aux populations panmictiques (où tous les individus peuvent interagir) :

1. Populations Multiples (Îles)

- Plusieurs sous-populations évoluant en parallèle.
- **Migrations** périodiques d'individus entre îles (typiquement les meilleurs).
- Avantages : meilleure diversité, parallélisation naturelle, convergence plus rapide.

2. Populations Cellulaires

- Individus organisés sur une grille régulière.
 - Sélection et croisement uniquement avec les voisins proches.
 - Avantage : propagation spatiale des bonnes solutions, meilleure exploration.
-

Théorème des Schémas (Schema Theorem)

Explication théorique du fonctionnement des AG :

- **Schéma** : motif binaire avec des positions fixes (0,1) et libres (*).
- Exemple : $1**1*0$ est un schéma d'ordre 3 (3 positions fixes).

Le théorème montre que les schémas **courts** ($\delta(S)$ petit), de **faible ordre** ($o(S)$ petit), et **supérieurs à la moyenne** ($f(S) > \bar{F}$) sont amplifiés de façon exponentielle.

$$M(t+1, S) \geq \frac{M(t, S)f(S, t)}{F(t)} \left[1 - p_c \frac{\delta(S)}{m-1} - o(S)p_m \right]$$

Les solutions optimales sont construites par concaténation de ces “blocs de construction” (building blocks).

Application à l'Optimisation Continue

Pour les fonctions $f : \mathbb{R}^d \rightarrow \mathbb{R}$, l'encodage binaire simple présente des limites de précision.

Encodage en Virgule Flottante

Représentation d'un nombre réel $x = s \times 2^t$ où :

- s : mantisse (précision p bits)
- t : exposant (q bits)

Standard IEEE 754 :

- Double précision (64 bits) : 1 bit signe, $p = 52$, $q = 11 \rightarrow \sim 16$ chiffres décimaux significatifs.
- Simple précision (32 bits) : 1 bit signe, $p = 23$, $q = 8 \rightarrow \sim 7$ chiffres décimaux significatifs.

Les opérateurs de croisement et mutation sont appliqués séparément sur la mantisse et l'exposant.

Exemple Synthétique : Optimisation de Couverture GSM

Problème : Positionner des antennes GSM dans une ville pour minimiser les zones de recouvrement tout en maximisant la couverture.

Solution par AG :

- **Individu** : carte d'intensité avec positions d'antennes.
- **Fitness** : qualité de couverture (calcul complexe, potentiellement coûteux).
- **Mutation** : déplacement d'antennes vers des positions acceptables.
- **Croisement** : fusion de régions complémentaires de deux cartes.
- **Avantage des AE** : capable de traiter cette fonction objectif complexe, multimodale, sans information de gradient.

Paramètres typiques :

- Taille population : 50-100
 - $p_{\text{crossover}}$: 0.6-0.8
 - p_{mutation} : 0.01-0.1
 - Critère d'arrêt : 100-500 générations ou stagnation
-

Conclusion

Les algorithmes évolutionnaires, et particulièrement les algorithmes génétiques, sont des méta-heuristiques puissantes pour l'optimisation difficile, notamment lorsque :

- La fonction objectif est complexe, multimodale, non différentiable.
- L'espace de recherche est vaste et mal structuré.
- Aucune information de gradient n'est disponible.

Leur force réside dans l'équilibre entre exploration et exploitation, maintenu par des opérateurs stochastiques et des mécanismes comme l'élitisme. Le réglage des paramètres (taille de population, probabilités d'opérateurs) reste crucial pour les performances.

Les variantes avancées (populations structurées, sélection par tournoi, encodage réel) étendent leur applicabilité à une large gamme de problèmes pratiques, de l'optimisation combinatoire à l'optimisation continue de haute dimension.